

«Спокуха»: подготовка к вопросам жюри

Это рабочий документ для команды. Вопросы отобраны по одному принципу: жюри видит только слайды и слышит только выступление, поэтому спрашивать будут про то, что на слайдах написано крупно, и про то, что в бизнесе всегда спрашивают, то есть про деньги, риски, сроки и поддержку. Сначала идут самые вероятные вопросы, потом вопросы по отдельным слайдам, потом узкие технические вопросы на случай, если в жюри окажется профильный специалист. В конце собраны все числа проекта в таблицах, чтобы можно было быстро найти любую цифру прямо во время ответа.

Три расхождения между слайдами и отчётом. Слайды менять нельзя, поэтому снимаем голосом.

Первое, слайд 11. На слайде написано: 1053 алерта, 36 уведомлений, снижение шума 96,6 процента, полнота 7 из 8. В отчёте стоят другие числа: 44 уведомления, 95,8 процента и полнота 8 из 8. Слайд показывает более раннюю версию, которая теряла один инцидент из восьми. Мы это исправили, и система стала отправлять дежурному 44 сообщения вместо 36, то есть на восемь сообщений больше за те же два часа. Хорошая новость в том, что слайд честно признаёт полноту 7 из 8, поэтому наш рассказ выглядит не как оправдание, а как продолжение работы.

Второе, слайд 13. В дереве КПЭ написано, что уведомлений на инцидент стало 4,5, а ошибочных адресаций 10. Актуальные числа: 5,5 и 13. Причина та же самая. Экономический итог при этом не изменился, потому что эффект считается не от этих чисел напрямую.

Третье, слайд 5. В описании пилота написано «Zabbix + SolarWinds», а на слайде 14 и в отчёте у нас Zabbix и Prometheus. Слайд 5 описывает контур заказчика, каким он задан во вводных кейса, а мы на своём стенде подняли Prometheus, потому что доступа к SolarWinds у нас не было. Для архитектуры это безразлично: любой источник подключается отдельным адаптером.

Contents

1 Самые вероятные вопросы	2
2 Вопросы по конкретным слайдам	5
2.1 Слайд 2, команда	5
2.2 Слайд 5, предпосылки и бизнес-требования	5
2.3 Слайд 7, архитектура	5
2.4 Слайд 9, обработка события	5
2.5 Слайд 11, искусственный интеллект	6
2.6 Слайд 12, информационная безопасность	6
2.7 Слайд 13, дерево КПЭ	7
2.8 Слайд 14, инфраструктура	7
3 Узкие технические вопросы	7

4 Если вопрос застал врасплох	9
5 Словарик: что означают наши термины	9
6 Все числа проекта в таблицах	10
6.1 Вводные данные кейса, описывающие проблему заказчика	10
6.2 Обязательные ставки для финансовой модели	11
6.3 Качество обработки: что на слайде и что актуально	11
6.4 Продуктовые метрики: база, достигнуто, цель	12
6.5 Собственные допущения финансовой модели	12
6.6 Расчёт эффектов	13
6.7 Затраты	13
6.8 Инвестиционные показатели при аренде, миллионы рублей	14
6.9 Сравнение аренды и покупки оборудования	14
6.10 Чувствительность модели	14
6.11 Замер потребления ресурсов на пилотном стенде	15
6.12 Целевая конфигурация узлов	16
6.13 Сводные числа по информационной безопасности	16
6.14 Прочие технические числа	17

1. Самые вероятные вопросы

Вопрос: Что из показанного реально работает, а что нарисовано?

Ответ: Работает сквозной путь: событие приходит из Zabbix или Prometheus, приводится к единой схеме, проходит корреляцию, превращается в уведомление и доставляется в TrueConf живому человеку. Работает веб-интерфейс со сводкой и каталогом систем. Работает локальная языковая модель. Мы специально сделали так, чтобы границу было видно без объяснений: на всех схемах сплошная рамка это то, что работает на стенде, а штриховая рамка это спроектированная, но ещё не реализованная часть. В самом интерфейсе разделы, не подключённые к данным, помечены баннером «Демонстрационные настройки». Мы принципиально нигде не показываем правдоподобные выдуманные данные.

Вопрос: Зачем разрабатывать своё, если на рынке есть готовые продукты?

Ответ: Ни один готовый продукт не проходит по ограничениям этого кейса одновременно. Зарубежные облачные сервисы вроде PagerDuty требуют вывода данных наружу и сейчас в России недоступны. Встроенные средства самих систем мониторинга видят только свои события, а нам нужна корреляция между семью системами сразу. Российские ITSM-платформы обычно требуют реального Active Directory и не умеют штатно работать с TrueConf. Плюс отдельное требование заказчика: языковая модель должна работать внутри контура, а не через внешний интерфейс. Наше решение закрывает всё это сразу.

Вопрос: Вы убрали 96 процентов уведомлений. Где гарантия, что вы не выбросили настоящую аварию?

Ответ: Это главный вопрос к любой системе фильтрации, и мы измеряем его отдельной метрикой. Она называется полнота и показывает, сколько инцидентов из имеющихся система вообще заметила. На слайде честно написано семь из восьми, то есть та версия действительно теряла один инцидент. Мы разобрались, почему так вышло, и добавили правило: если критичность растёт выше того уровня, который система уже видела по этому сервису, уведомление отправляется всегда. После этого полнота стала восемь из восьми. Заплатили мы за это тем, что система стала отправлять дежурному 44 сообщения вместо 36, то есть на восемь сообщений больше за те же два часа, а снижение шума уменьшилось с 96,6 до 95,8 процента. Мы сознательно пошли на этот размен, потому что для системы оповещения пропущенная авария несопоставимо дороже восьми лишних сообщений.

Вопрос: Сколько нужно денег и времени, чтобы довести это до промышленной эксплуатации?

Ответ: Пилот уже стоил 1920 человеко-часов, это шесть человек за восемь недель, или 6,7 миллиона рублей по ставке кейса. Для промышленной эксплуатации нужно закрыть список задач первого приоритета, он у нас составлен и приоритизирован: аутентификация источников событий, приоритетные очереди для критичных алертов, хранилище секретов, резервный путь оповещения на случай отказа платформы, контроль молчания источников. По нашей оценке это ещё один сопоставимый цикл работ. Дальше идёт сопровождение, это 30 часов в месяц, и инфраструктура, 0,76 миллиона рублей в год при аренде.

Вопрос: Кто будет всё это поддерживать после вас?

Ответ: Решение спроектировано так, чтобы повседневная эксплуатация не требовала разработчика. Роли, правила классификации, маршрутизация и пороги это настройки в таблицах, а не код: добавить роль или изменить правило может администратор через интерфейс. Разработчик нужен только для подключения принципиально нового источника, и это написание одного адаптера, ядро при этом не меняется. Заложенная нами трудоёмкость сопровождения это 30 часов в месяц, то есть примерно четверть ставки одного человека.

Вопрос: У вас пилот на 87 пользователей и четыре филиала. Что будет, когда масштабируете на всю Группу?

Ответ: Мы закладывали рост с самого начала, и на слайде 14 показано, что каждый из трёх узлов растёт по своей оси. Узел приложений растёт горизонтально, просто добавлением копий, потому что они делят нагрузку через Kafka. Узел данных растёт вертикально, ему нужны процессор и диск. Узел искусственного интеллекта растёт добавлением видеокарт. Подключение нового филиала или новой системы мониторинга не требует остановки платформы и не требует переработки ядра. Честно назовём и ограничение: сейчас это масштабирование виртуальными машинами, а не оркестратором, поэтому оно даёт производительность, но не даёт отказоустойчивости. Для непрерывной работы понадобится оркестратор, и это у нас записано в план.

Вопрос: Окупаемость 0,8 года выглядит слишком красиво. Откуда такие числа?

Ответ: Почти весь эффект даёт не экономия рабочего времени, а сокращение простоя. Стоимость простоя не наша, она задана вводными кейса: 150 миллионов рублей в сутки,

то есть 6,25 миллиона рублей в час. При такой цене достаточно предотвратить всего полтора часа простоя за год, чтобы получить 9,4 миллиона рублей эффекта. Именно поэтому окупаемость такая быстрая. И обратная сторона та же самая: если мы пропустим один серьёзный инцидент, годовой эффект обнулится. Поэтому полнота обнаружения у нас стоит в дереве КПЭ как контрольный показатель, а не как второстепенная метрика.

Вопрос: Простой установки НПЗ стоит 150 миллионов в сутки, но вы же делаете систему оповещения. При чём тут НПЗ?

Ответ: Мы не приписываем себе весь простой. Мы считаем только ту его часть, которая возникает из-за задержки реакции, то есть пока авария тонет в потоке уведомлений и пока она идёт не тому дежурному. Во вводных кейса сказано, что простой остаётся незамеченным в среднем 14 минут. Мы закладываем сокращение на 15 минут на инцидент и всего шесть значимых инцидентов в год. Это осознанно скромная оценка: полтора часа простоя за целый год.

Вопрос: Не опасно ли доверять оповещение искусственному интеллекту? Что если он ошибётся?

Ответ: У нас искусственный интеллект в принципе не может испортить оповещение, потому что он не принимает решений. Все решения принимает обычная система правил: что считать критичным, что дублем, кого уведомить и когда отправить. Модель только добавляет пояснение и формулирует понятный текст, причём работает параллельно и не задерживает доставку. Если модель ошиблась, недоступна или вернула бессмыслицу, уведомление всё равно уйдёт, просто с текстом, собранным из полей алерта. Это проверяется автоматическим тестом. И отдельно: модели запрещено понижать или скрывать критичные алерты, такое решение принимается только правилами.

Вопрос: Данные никуда не уходят? Что с импортозамещением?

Ответ: Наружу не уходит ничего, включая работу языковой модели. Модель работает на нашем сервере, а сетевые правила запрещают ИИ-зоне выход в интернет. Внешних облачных сервисов в решении нет вообще, лицензионных отчислений тоже нет: Python, Kafka, TimescaleDB, nginx и vLLM это свободное программное обеспечение, а модель Qwen открытая и работает локально. Персональные данные мы не обрабатываем вовсе, в базе только технические идентификаторы.

Вопрос: Почему TrueConf? А если мы захотим другой мессенджер?

Ответ: TrueConf это обязательное требование кейса, поэтому он сделан как штатный, обязательный канал доставки. Но архитектурно канал доставки это отдельный компонент: диспетчер публикует запрос на уведомление, а адаптер канала его забирает. Добавить электронную почту, SMS или другой мессенджер это написать ещё один такой адаптер, ядро при этом не трогается.

Вопрос: Чем вы отличаетесь от других команд, которые делают тот же кейс?

Ответ: Скорее всего тем, что мы всё измерили и показываем неудобные числа тоже. Мы не заявляем снижение шума, а измеряем его на воспроизводимом наборе данных и вместе с ним показываем полноту обнаружения и точность адресации, включая то, что 13 уведомлений из 44 пока уходят не тому дежурному. Мы честно отмечаем на схемах, что реализовано, а что только спроектировано, и в интерфейсе помечаем макеты баннером.

И у нас работающий сквозной путь на реальном стенде, а не презентация.

2. Вопросы по конкретным слайдам

2.1. Слайд 2, команда

Вопрос: Кто в команде чем занимался?

Ответ: Шесть человек: архитектор отвечал за структуру решения и границы контуров, три разработчика делали ядро обработки, интерфейс и интеграции, специалист по информационной безопасности вёл модель угроз и реестр рисков, аналитик занимался требованиями, матрицей трассировки и экономикой. Такой состав дал нам возможность смотреть на задачу не только с технической стороны, но и со стороны пользователя и реальной эксплуатации.

2.2. Слайд 5, предпосылки и бизнес-требования

Вопрос: Откуда взялись 5400 событий, 65 процентов шума и 3,2 миллиона за инцидент?

Ответ: Это вводные данные кейса, их дал заказчик, мы их не придумывали. Наши собственные измерения это отдельная история, они сделаны на нашем наборе данных, и там другие абсолютные числа, потому что это наш пилотный периметр, а не все системы заказчика.

Вопрос: На слайде написано Zabbix и SolarWinds, а показываете вы Prometheus.

Ответ: На слайде описан контур заказчика, каким он задан во вводных кейса. Доступа к SolarWinds у нас не было, поэтому на стенде мы подняли Prometheus вместе с Alertmanager, это распространённая система мониторинга с другим форматом сообщений. Для нас важно было проверить именно разноформатность, то есть что два непохожих источника сводятся к единой схеме. SolarWinds подключается точно так же, отдельным адаптером, ядро при этом не меняется.

2.3. Слайд 7, архитектура

Вопрос: Почему Active Directory стоит сбоку и не участвует в аутентификации?

Ответ: Это ограничение кейса: доступа к домену у нас нет. Мы превратили ограничение в архитектурное решение: вход выполняется через TrueConf по протоколу OAuth 2, тот самый TrueConf, который у нас и так обязателен как канал доставки. Active Directory остался справочником подразделений и команд, причём платформа в него только читает и никогда ничего не записывает. Когда домен станет доступен, подключить его можно будет без переделки, потому что вход у нас отдельный компонент.

2.4. Слайд 9, обработка события

Вопрос: Что такое «детерминированное ядро» простыми словами и почему это преимущество?

Ответ: Это означает, что решения принимает система понятных правил, а не нейросеть. Правило можно прочитать, проверить и поправить, и оно всегда даёт один и тот же результат на одних и тех же данных. Практическая польза простая: когда система ошиблась, инженер открывает решение, видит, какое именно правило сработало, и точно его донастраивает. С нейросетью в этой роли пришлось бы гадать. Плюс правила работают всегда, даже когда модель недоступна.

2.5. Слайд 11, искусственный интеллект

Вопрос: На слайде полнота 7 из 8. Получается, вы потеряли инцидент?

Ответ: Та версия, которая на слайде, действительно теряла один инцидент из восьми, и мы это не прячем. Причина оказалась понятной: второй инцидент начинался, когда первый ещё расходился каскадом по тем же сервисам, и система считала его продолжением первого. Мы добавили правило эскалации: если критичность по сервису выросла выше того уровня, который система уже видела, уведомление отправляется обязательно, даже если до этого система решила придержать сигнал. Сейчас полнота восемь из восьми. Стоило это восьми дополнительных сообщений дежурному за два часа, было 36, стало 44. Половина из этих восьми попала правильному адресату, так что размен нас полностью устраивает.

Вопрос: Зачем вам вообще искусственный интеллект, если решения принимают правила?

Ответ: Он делает уведомление понятным человеку. Правила определяют, что случилось и кого звать, а модель добавляет к этому связное объяснение, гипотезу о первопричине и первый шаг проверки. Дежурный получает не строку с метрикой и порогом, а нормальный текст. При этом мы сознательно оставили модель в роли помощника: если убрать её совсем, система продолжит работать, просто уведомления станут суше.

2.6. Слайд 12, информационная безопасность

Вопрос: Вы сами пишете, что webhook не аутентифицирован. Разве такое можно внедрять?

Ответ: В таком виде нельзя, и именно поэтому мы вынесли это первым пунктом в остаточные риски. На изолированном стенде это допустимо, в промышленной эксплуатации недопустимо. Мы предпочли показать честный список того, что осталось закрыть, а не рисовать зелёные галочки. Всего у нас 23 сценария угроз: шесть закрыты полностью, одиннадцать частично, три требуют работы до внедрения, три неактуальны.

Вопрос: Почему именно угрозы искусственного интеллекта закрыты полностью?

Ответ: Потому что мы не дали модели никаких полномочий. Она не пишет в базу, не

меняет настройки, не отправляет уведомления и не может понизить критичность. Текст алерта приходит к ней как данные, отдельно от инструкции, а ответ принимается только в пределах заранее заданного списка значений. Это не навешенное сверху средство защиты, это следствие архитектуры, поэтому такие угрозы закрыты не частично, а полностью.

2.7. Слайд 13, дерево КПЭ

Вопрос: Как вы вообще перешли от уведомлений к рублям?

Ответ: В два шага, и оба видны на слайде. Сначала измеренные метрики превращаются в физические величины: сэкономленные человеко-часы и сокращённые часы простоя. Потом эти величины умножаются на обязательные ставки кейса, то есть на 2000 рублей за час работы сотрудника и 6,25 миллиона рублей за час простоя. Получается 2,45 миллиона рублей на трудозатратах и 9,38 миллиона на простое, вместе 11,8 миллиона рублей в год.

Вопрос: Ваша экономия рабочего времени выглядит скромно на фоне 48 человеко-часов в сутки из вводных.

Ответ: Так и есть, и это сделано намеренно. Наивный расчёт дал бы огромное число, но он был бы неправдой: сегодня эти часы на самом деле не тратятся, поток уведомлений просто игнорируется, и именно поэтому теряются аварии. Поэтому мы ограничились эффектом реальным фондом времени дежурных и взяли только ту часть, которая действительно высвобождается. Получилось скромно, зато защитимо.

2.8. Слайд 14, инфраструктура

Вопрос: Зачем вам отдельный сервер с видеокартой? Это дорого.

Ответ: Видеокарта нужна потому, что модель постоянно держит в видеопамяти около 14 гигабайт, независимо от того, есть нагрузка или нет. Держать такой ресурс внутри общего сервера расточительно, поэтому мы вынесли его отдельно. По деньгам это 45 тысяч рублей в месяц из 63 тысяч, то есть 71 процент стоимости всей инфраструктуры. И тут есть важное следствие: если заказчик решит, что искусственный интеллект ему не нужен, этот узел просто выключается, система продолжает работать, а инфраструктура дешевеет с 0,76 до 0,22 миллиона рублей в год.

Вопрос: Три виртуальные машины на 87 пользователей. Не избыточно ли?

Ответ: Нет, потому что размер узлов определяется не числом пользователей, а профилем нагрузки. Мы сняли замер работающего стенда: наши собственные приложения занимают меньше 150 мегабайт памяти, а основные потребители это шина сообщений и модель. Разделение на три узла нужно не ради запаса, а ради того, чтобы эти три разные нагрузки не мешали друг другу и росли независимо. Запас по узлу приложений при этом действительно большой, примерно пятидесятикратный, и он бесплатный.

3. Узкие технические вопросы

Этот раздел на случай, если в жюри окажется профильный специалист.

Вопрос: Почему Kafka, а не более простая очередь или прямые вызовы?

Ответ: Нам нужна была журналируемая шина, где сообщения хранятся, а не исчезают после доставки. Это даёт три вещи: недоступность потребителя не теряет события, обработчики масштабируются горизонтально за счёт групп потребителей, и приём событий отделён от их обработки, поэтому всплеск нагрузки переживается буфером. Прямые синхронные вызовы создавали бы обратное давление на приём, а это запрещено требованиями.

Вопрос: Почему TimescaleDB?

Ответ: События и алерты это временные ряды, и гипертаблицы сразу дают сжатие и политики хранения: у нас события и алерты живут 90 дней, а решения искусственного интеллекта 400 дней. При этом под капотом остаётся обычный PostgreSQL, поэтому реляционная часть с ролями и связями живёт в той же базе. В итоге одна СУБД вместо двух.

Вопрос: Как именно работает корреляция?

Ответ: Каждый алерт получает ключ: явный идентификатор корреляции, если он есть, иначе сервис, иначе пара из источника и метрики. На каждый ключ в пределах временного окна работает конечный автомат, который решает, что это: повтор, дополнительное свидетельство той же аварии, нестабильный источник или новая авария, требующая уведомления. Важная деталь: состояние не хранится в изменяемом поле, оно каждый раз выводится проигрыванием всего окна заново, поэтому оно не может разойтись с историей.

Вопрос: Что происходит при отказе базы данных?

Ответ: Обработка и доставка продолжают, сбой записи не выходит в поток обработки, и это подтверждено тестом. Теряется только история за время отказа. Мы считаем это правильным приоритетом для системы оповещения, но не считаем идеалом: подтверждение приёма только после надёжного сохранения стоит у нас в списке первого приоритета.

Вопрос: Как вы измеряли качество и почему это не подгонка?

Ответ: Мы построили набор из 1053 алертов, где 545 значимых и 508 шумовых, восемь инцидентов и два часа модельного времени с фиксированным начальным значением генератора. Разметка не проставлена руками, она выводится теми же правилами, которые порождают события. Ключевой момент честности: разметка не попадает в конвейер. Корреляция не видит идентификатор инцидента, иначе она сгруппировала бы алерты именно по нему и показала бы идеальный результат по совершенно неверной причине. Границу измерения мы тоже называем прямо: один и тот же источник задаёт и шум, и критерий шума, поэтому это честный стенд для сравнения версий между собой, но не доказательство эффективности на реальном трафике.

Вопрос: Что с тестированием?

Ответ: 145 тестов платформы проходят успешно, один пропущен, потому что требует развёрнутой модели, четыре помечены как известные ограничения. Отдельно покрыты диспетчер доставки и генератор событий. Тестами зафиксированы именно те свойства, на которых держится экономика: отключение модели не останавливает доставку, ответ вне словаря не применяется, отказ базы не прерывает обработку, некорректный web-hook отклоняется.

Вопрос: Точность 31,8 процента, это же мало.

Ответ: Мало, и мы измерили это сами, а не ждали, пока заметят. Причина конкретная: 13 уведомлений из 44 уходят дежурному того сервиса, который сигнализирует о проблеме, а не того, который сломался. Лечится это учётом первопричины и данными сервисного каталога при маршрутизации, и это основная задача следующего этапа. Цель 60 процентов, и проверяться она будет на том же наборе данных.

Вопрос: Как подключить новую систему мониторинга?

Ответ: Написать адаптер, ядро не трогается. Есть два способа подключения: либо источник сам вызывает нас по webhook, либо мы опрашиваем его по расписанию. Формат данных полностью принадлежит адаптеру. Внутренняя схема события минимальная и открытая: обязательны только источник и статус, а остальные поля вендора сохраняются как есть, поэтому миграция базы не нужна.

4. Если вопрос застал врасплох

Три правила на такой случай. Первое: если числа нет в голове, не выдумывайте, скажите, что оно есть в отчёте, и назовите порядок величины. Второе: если вопрос про то, чего мы не сделали, отвечайте прямо, что не сделали, и сразу называйте, в какой очереди это стоит и почему именно там. Слабость, названная первой, перестаёт быть слабостью. Третье: если вопрос выходит за рамки того, что мы проверяли, так и скажите, и добавьте, каким измерением это можно было бы проверить.

5. Словарик: что означают наши термины

Здесь простыми словами объяснено то, что звучит в выступлении и в ответах. Пригодится, если вопрос задаст нетехнический член жюри и объяснять придётся на ходу.

Термин	Что это значит простыми словами
Событие	Любая запись, которую прислала система мониторинга. Само по себе оно ещё ничего не значит
Алерт	Событие, которое система мониторинга сочла достойным внимания: превышен порог, упал сервис, кончилось место
Инцидент	Одна настоящая авария. Одна авария обычно порождает десятки алертов из разных систем, поэтому инцидентов всегда сильно меньше

Уведомление	Сообщение, которое реально уходит живому дежурному. Наша задача в том, чтобы из тысячи алертов получилось несколько уведомлений
Шум	Алерты, которые не требуют реакции человека: повторы, мелочь, следствия уже известной аварии
Полнота	Про сколько настоящих аварий система вообще сообщила. У нас 8 из 8: ни одна авария не осталась незамеченной. Это защита от самой дорогой ошибки, то есть от молчания при настоящей аварии
Точность	Какая доля отправленных сообщений оказалась полезной. У нас 14 верных из 44 отправленных, это 31,8 процента. Точность и полнота тянут в разные стороны: отправляя всё подряд, получишь идеальную полноту и ужасную точность
Дедупликация	Отсечение повторов: одна и та же проблема повторяется каждую минуту, а человеку сообщаем один раз
Корреляция	Склейка разных сигналов, у которых одна причина. Упал сервер, и об этом закричали и Zabbix, и Prometheus, и сервисы сверху: это один инцидент, а не пять
Эскалация	Правило, по которому мы обязаны сообщить, даже если до этого решили промолчать. У нас оно срабатывает, когда критичность выросла выше уже виденного уровня
Детерминированность	Работающий по понятным правилам, а не по догадке нейросети. Правило можно прочитать, проверить и поправить, и оно всегда даёт один и тот же результат
Fallback, резервный путь	Что система делает, когда что-то сломалось. У нас: если модель недоступна, текст уведомления собирается из полей алерта, и уведомление всё равно уходит
Маршрутизация	Определение, кому именно отправить: по сервису находим команду, по команде дежурного, по дежурному канал доставки
FTE	Условный сотрудник на полной ставке. Ставка кейса 2000 рублей за час его работы
NPV, чистая приведённая стоимость	Сколько проект приносит за три года с поправкой на то, что рубль завтра дешевле рубля сегодня. У нас 13,9 миллиона
DPР, срок окупаемости	Через сколько проект вернёт вложенное. У нас 0,8 года
PI, индекс доходности	Во сколько раз отдача больше вложений. У нас 3,1

6. Все числа проекта в таблицах

6.1. Вводные данные кейса, описывающие проблему заказчика

Параметр	Значение
Систем мониторинга	7
Событий в сутки	около 5400
Доля шума	65 процентов
Ручной разбор	около 48 человеко-часов в сутки
Простой остаётся незамеченным в среднем	14 минут
Стоимость одного инцидента	около 3,2 миллиона рублей
Охват пилота	4 филиала, около 87 пользователей
Источники пилота по вводным	Zabbix и SolarWinds; на нашем стенде Zabbix и Prometheus
Требуемое время доставки уведомления	2–3 минуты
Обновление дашборда	не дольше 5 минут; новое событие на панели до 15 секунд

6.2. Обязательные ставки для финансовой модели

Параметр	Значение
Стоимость FTE, применяется при расчёте эффектов	2000 рублей в час
Час работы проектной команды, применяется при расчёте затрат	3500 рублей в час
Простой установки НПЗ	150 миллионов рублей в сутки, то есть 6,25 миллиона в час

6.3. Качество обработки: что на слайде и что актуально

Параметр	Значение
Состав набора данных	1053 алерта, из них 545 значимых и 508 шумовых; 8 инцидентов; 2 часа модельного времени
Без фильтрации	1053 уведомления; снижение шума 0 процентов; полнота 8 из 8; точность 20,5 процента
Версия на слайде 11	36 уведомлений; снижение шума 96,6 процента; полнота 7 из 8 ; точность 27,8 процента
Актуальная версия	44 уведомления; снижение шума 95,8 процента; полнота 8 из 8; точность 31,8 процента

Как распределились 44 уведомления	14 адресованы верно, 13 ушли не тому дежурному, 17 остались шумовыми, причём из них лишь одно относится к окну обслуживания
Как распределилась базовая линия	216 верных, 329 не тому адресату, 508 шумовых
Что дало правило эскалации	Полнота выросла с 7 из 8 до 8 из 8. Дежурный стал получать на 8 сообщений больше за два часа, было 36, стало 44; из этих восьми четыре попали верному адресату. Снижение шума уменьшилось с 96,6 до 95,8 процента, а точность выросла с 27,8 до 31,8 процента

6.4. Продуктовые метрики: база, достигнуто, цель

Метрика	База	Достигнуто	Цель
Уведомлений за 2 часа набора данных	1053	44	не более 50
Уведомлений в час	527	22	не более 25
Уведомлений на один инцидент	132	5,5 (на слайде 4,5)	не более 6
Шумовых уведомлений	508	17	не более 10
Уведомлений не тому адресату	329	13 (на слайде 10)	не более 5
Доля полезных уведомлений	20,5 %	31,8 %	не менее 60 %
Полнота обнаружения инцидентов	8 из 8	8 из 8	8 из 8
Время до первого уведомления	не измерялось	не измерялось	не более 15 с
Доля немаршрутизируемых алертов	не измерялось	не измерялось	не более 5 %
Доставка при недоступности ИИ	не измерялось	100 %	100 %

6.5. Собственные допущения финансовой модели

Параметр	Значение	Обоснование
Поток алертов пилотного периметра	12 636 штук в сутки	Измеренный набор данных, умноженный на 12

Среднее время реакции на уведомление	2 минуты	Время открыть, прочитать и квалифицировать оповещение
Дежурные смены	2 смены по 8 часов	Типовая организация дежурства
Доля времени дежурного на разбор оповещений	30 процентов	Ограничивает эффект фактическим фондом времени
Доля высвобождаемого времени	70 процентов	Часть разбора остаётся при любом снижении шума
Значимых инцидентов с простым в год	6	Оценка пилотного периметра, уточняется по журналу аварий
Сокращение времени обнаружения на инцидент	15 минут	Следствие снижения числа уведомлений и адресной доставки
Состав проектной команды	6 человек	Архитектор, три разработчика, специалист по ИБ, аналитик
Трудоёмкость пилота	1920 часов	6 человек, 8 недель, по 40 часов
Трудоёмкость сопровождения	30 часов в месяц	Поддержка адаптеров, правил и конфигурации
Ставка дисконтирования	20 процентов	Типовая для проектов внутренней ИТ-автоматизации
Горизонт расчёта	3 года	Срок жизни пилотного решения до пересмотра

6.6. Расчёт эффектов

Расчёт	Результат
Трудовозатраты: 16 человеко-часов в сутки, из них 30 процентов даёт 4,8; из них высвобождается 70 процентов, это 3,36 в сутки; за год примерно 1226 человеко-часов; умножаем на 2000 рублей	2,45 миллиона рублей в год
Простой: 6 инцидентов по 0,25 часа дают 1,5 часа в год; умножаем на 6,25 миллиона рублей за час	9,38 миллиона рублей в год
Суммарный операционный эффект	11,8 миллиона рублей в год

6.7. Затраты

Статья	Расчёт	Сумма
Разработка и внедрение пилота	1920 часов по 3500 рублей	6,7 миллиона рублей, разово
Сопровождение и развитие	360 часов в год по 3500 рублей	1,3 миллиона рублей в год

Инфраструктура, аренда трёх узлов	63 тысячи рублей на 12 месяцев	0,76 миллиона рублей в год
Лицензии внешних сервисов	отсутствуют	0
Итого		6,7 миллиона рублей разово и 2,0 миллиона рублей в год

Инфраструктура по месяцам: узел приложений (4 vCPU, 8 ГБ памяти, 50 ГБ диска) стоит 6 тысяч рублей, узел данных и шины (8 vCPU, 16 ГБ памяти, 200 ГБ SSD) стоит 12 тысяч рублей, узел искусственного интеллекта с видеокартой на 16 ГБ стоит 45 тысяч рублей, всего 63 тысячи рублей в месяц. На долю ИИ-узла приходится 71 процент. Если функции искусственного интеллекта выключить, инфраструктура обойдётся в 0,22 миллиона рублей в год.

6.8. Инвестиционные показатели при аренде, миллионы рублей

Показатель	Год 0	Год 1	Год 2	Год 3
Эффект	нет	11,8	11,8	11,8
Операционные затраты	нет	2,0	2,0	2,0
Инвестиции	6,7	нет	нет	нет
Чистый поток	–6,7	9,8	9,8	9,8
Коэффициент дисконтирования при ставке 20 %	1,00	0,83	0,69	0,58
Дисконтированный поток	–6,7	8,2	6,8	5,7
Накопленный дисконтированный поток	–6,7	1,5	8,3	13,9

Итог: чистая приведённая стоимость **13,9 миллиона рублей**, приведённая стоимость 20,7 миллиона, приведённые инвестиции 6,7 миллиона, индекс доходности **3,1**, срок окупаемости **около 0,8 года**, то есть примерно десять месяцев.

6.9. Сравнение аренды и покупки оборудования

Показатель	Аренда	Покупка
Разовые инвестиции, миллионы рублей	6,7	9,06
Стоимость оборудования, миллионы рублей	не требуется	2,36, из них узел с видеокартой 1,66
Периодические затраты, миллионы рублей в год	2,0	1,65

Чистая приведённая стоимость за 3 года	13,9	12,3
Срок окупаемости, лет	0,8	1,1

6.10. Чувствительность модели

Утверждение	Число
Сколько простоя нужно предотвратить, чтобы покрыть все затраты первого года, а это 8,7 миллиона рублей	1,4 часа в год
Чистая приведённая стоимость, если полностью обнулить эффект от экономии трудозатрат	около 8,8 миллиона рублей
Цена ошибки в один час простоя	6,25 миллиона рублей в год
Последствие одного пропущенного бизнес-критичного инцидента	может обнулить весь годовой эффект

6.11. Замер потребления ресурсов на пилотном стенде

Стенд это виртуальная машина с 16 vCPU, 62 ГБ оперативной памяти, 133 ГБ диска и видеокартой Tesla T4 на 15 ГБ. На ней работает 15 контейнеров, аптайм на момент замера пять суток. Замер снят в режиме ожидания, поэтому показывает базовое, а не пиковое потребление.

Компонент	Процессор	Память	Примечание
Платформа, основной процесс	0,4 %	65 МБ	Приём, корреляция, программный интерфейс
Веб-интерфейс	менее 0,1 %	13 МБ	Статика и обратный прокси
TimescaleDB	0,8 %	384 МБ	Растёт вместе с объёмом истории
Kafka	181 %	1,2 ГБ	В простое занимает около 1,8 ядра
Генератор событий	0,4 %	40 МБ	Существует только на стенде
Инференс vLLM	1,2 %	4,0 ГБ	Плюс 13,6 из 15,4 ГБ видеопамати
TrueConf Server	0,5 %	1,25 ГБ	Внешняя система, обычно уже есть
Контроллер домена	0,2 %	255 МБ	Синтетический справочник стенда
Zabbix, четыре контейнера	1,1 %	945 МБ	Источник событий, обычно уже есть

Prometheus	менее 0,1 %	44 МБ	Источник событий и метрик
Сервис CMDB	0,1 %	33 МБ	Развёрнут, но пока не используется
TLS-фронт	менее 0,1 %	16 МБ	Терминация TLS
Итого	около 1,9 ядра	около 9 ГБ	Диск: 38 ГБ образов и 2,2 ГБ томов

6.12. Целевая конфигурация узлов

Узел	Конфигурация	Чем ограничен и как растёт
Приложения	4 vCPU, 8 ГБ, 50 ГБ	Ограничен числом экземпляров, а не ресурсами; растёт горизонтально; запас примерно пятидесятикратный
Данные и шина	8 vCPU, 16 ГБ, 200 ГБ SSD	Ограничен процессором и диском; растёт вертикально и вместе со сроком хранения
Искусственный интеллект	8 vCPU, 32 ГБ, видеокарта 16 ГБ	Ограничен видеопамью и числом одновременных запросов; растёт добавлением узлов с видеокартами
Интеграции	Ресурсы заказчика	Zabbix, Prometheus, каталог и TrueConf обычно уже развёрнуты, в расчёт затрат не входят

6.13. Сводные числа по информационной безопасности

Параметр	Значение
Разобрано сценариев угроз	23
Нейтрализовано полностью	6, включая все угрозы ИИ-контура
Нейтрализовано частично	11
Требуется работы до внедрения	3: неаутентифицированный webhook У-01, подмена образа или весов модели У-16, отказ единственного узла У-18; рядом стоит контроль молчания источника У-19
Неактуальны для нашей архитектуры	3: персональные данные, база знаний, обращения к CMDB и каталогу
Категорий нарушителей	7, от внешнего без доступа к сети до автора текста алерта
Границ доверия	6; граница между ядром и ИИ реализована полностью

Тесты платформы	145 пройдено, 1 пропущен, 4 отмечены как известные ограничения
Утверждений о защите, подтверждённых автотестами	7
Сроки хранения	события и алерты 90 дней, решения ИИ 400 дней

6.14. Прочие технические числа

Параметр	Значение
Время вызова модели для формулировки уведомления	около 3,4 секунды на видеокарте Tesla T4
Словарь приоритетов, доступный модели	p1, p2, p3, p4
Архитектурных решений в матрице трассировки	17
Требований к интеллектуальной обработке	14 позиций: 9 реализовано, 4 частично, 1 отнесена к целевой архитектуре
Этапов плана внедрения	5: наблюдение, затем корреляция и маршрутизация, затем теневой и подсказывающий режимы, затем расширение периметра, затем ограниченная автоматизация
Ответ на некорректную нагрузку webhook	код 422
Ответ нереализованных методов интерфейса	код 501, а не пустой список
Порты пилотного стенда	Zabbix 8080; Prometheus 9090 и 9093; генератор событий 8090; платформа 8100; веб-интерфейс 8091; уведомления 8110; бот TrueConf 8120; TrueConf Server 80, 443, 4307; TLS-фронт 8443 и 8543; база данных портов не публикует