



21'

26'

31'

36'

41'


РАЗРАБОТКА ИНТЕЛЛЕКТУАЛЬНОЙ СИСТЕМЫ
УПРАВЛЕНИЯ ОПОВЕЩЕНИЯМИ ДЛЯ ОБЕСПЕЧЕНИЯ
НЕПРЕРЫВНОСТИ БИЗНЕС-КРИТИЧНЫХ ПРОЦЕССОВ.
«СПОКУХА»

36'

«Спокойствие только
спокойствие»

41'

46'





**МАКСИМ
НИКОЛАЕВ
КАПИТАН**

**ОЛЕГ
АЛЕКСАНДРОВ
АРХИТЕКТОР**

**ЕЛИЗАВЕТА
БЕРДНИКОВА
РАЗРАБОТЧИК**

**АНВАР
ХАБИРОВ
РАЗРАБОТЧИК**

**ИГОРЬ
КОТЕЛЬНИКОВ
ИНФРАСТРУКТУРА**

**АЛИНА
ГАРИФУЛЛИНА
СИСТЕМНЫЙ
АНАЛИТИК**



26'

31'

36'

41'

Цель:

Снизить операционные потери от простоев бизнес-критичных сервисов и трудозатраты на обработку алертов

Образ результата:

- ★ Веб-портал с ЛК и админ-панелью: self-service подписки, классификация критичности, маршрутизация правил.
- ★ Near-online дашборд + управление пользователями.
- ★ Интеграция с TrueConf (уведомления, авторизация без AD).
- ★ Обработка разноформатных событий, включая ИИ-сценарий (≥ 1).

Задачи:

★ Интеграция с 2–7 системами мониторинга (разные форматы событий).

★ Обработка: дедупликация, корреляция, классификация критичности, саммаризация.

★ Экономическое обоснование целевых KPI: MTTR $\leq$ 20 мин, ложные срабатывания $\leq$ 5%.

★ Админ-дашборд: нагрузка, % доставленных, топ инцидентов.

★ ЛК пользователя: текущие аварии, self-service подписки, история уведомлений.

★ TrueConf: доставка уведомлений + авторизация (без AD).

ПРЕДПОСЫЛКИ И БИЗНЕС-ТРЕБОВАНИЯ

ПРЕДПОСЫЛКИ • ПРОБЛЕМЫ / ВОЗМОЖНОСТИ

7 систем мониторинга ежедневно генерируют ~5 400 событий; 65% уведомлений - информационный шум.

Разные форматы сообщений и отдельные настройки получателей затрудняют единое управление подписками и масштабирование.

48 человеко-часов в сутки уходит на ручную обработку L1; среднее время незамеченного простоя — 14 минут (~3,2 млн руб. потеря за инцидент).

ТЕКУЩАЯ СИТУАЦИЯ

Принято решение создать единую платформу: централизованный прием → обработка → доставка уведомлений по правилам.

Пилот: Zabbix + SolarWinds, 4 филиала, 87 пользователей; далее — масштабирование на Группу.

Целевой эффект: меньше избыточных уведомлений, быстрее реакция на критические события, ниже трудозатраты администрирования.

БИЗНЕС-ТРЕБОВАНИЯ

Единый контур событий: универсальный API, Webhook/HTTP, нормализация и хранение истории.

Интеллектуальная обработка: критичность, дедупликация, корреляция, первопричина и краткая сводка.

Self-service подписки и маршрутизация: TrueConf обязателен; LDAP/AD, роли, аудит и новые каналы — конфигурируемо.

НЕФУНКЦИОНАЛЬНЫЕ ТРЕБОВАНИЯ


ПРОИЗВОДИТЕЛЬНОСТЬ • НАДЁЖНОСТЬ

- ★ Время доставки — уведомление — не более 2–3 мин от поступления события на пилоте.
- ★ Обновление дашбордов — не более 5 мин.
- ★ Производительность — до 5–6 тыс. событий/сутки от 7 систем.
- ★ Буферизация входящего потока — без потери событий при кратковременных пиковых нагрузках.
- ★ Приоритизация очереди — critical/high обрабатываются в первую очередь.
- ★ Надёжность доставки — fallback при недоступности основного канала; эскалация неподтверждённых уведомлений.
- ★ Аудит решений — сохранение идентификатора правила/модели принятия решения.
- ★ Ограничение рассылки — настраиваемый лимит получателей и сообщений по одному инциденту.

БЕЗОПАСНОСТЬ • МАСШТАБИРУЕМОСТЬ

- ★ Резервное копирование — периодическая проверка восстановления истории событий и конфигурации.
- ★ Типы данных — ПДн и чувствительные данные не передаются во внешние облачные ИИ-сервисы.
- ★ Журналирование — аудит действий пользователей и администраторов.
- ★ Rate limiting — ограничение запросов к API для защиты от перегрузки.
- ★ Совместимость с AD/LDAP — архитектурная готовность к интеграции с корпоративным каталогом.
- ★ Подключение новых источников — через адаптер без изменения ядра платформы.
- ★ Использование ИИ — внутри контура компании; без передачи данных во внешние облака.
- ★ Масштабируемость подписок — увеличение числа источников, пользователей и каналов без переработки ядра.

Границы системы и внешние участники



Обозначения: сплошная рамка — реализовано на пилоте; штриховая — целевая архитектура

Используемые технологии

Бэкенд:

Python, FastAPI

Обработка данных и очереди:

Apache Kafka

База данных:

TimescaleDB

ИИ и машинное обучение:

vLLM, Qwen

Интерфейс и прокси:

HTML/JS, nginx

Интеграции:

TrueConf Chatbot API, Samba AD DC (как номинальный справочник).

Контейнеризация:

Docker Compose

ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ: ПРИЁМ И ОБРАБОТКА СОБЫТИЙ

1. ПРИЕМ И НОРМАЛИЗАЦИЯ

Webhook API

/v1/integrations/<slug>/webhook → адаптер по slug; некорректная нагрузка → HTTP 422.

Polling / восстановление

Асинхронный итератор опрашивает источник; Zabbix сверяется по расписанию для восстановления пропущенных событий.

Единая открытая схема

Минимум: source + status; время подставляется при отсутствии; vendor-поля сохраняются без миграции схемы.

Строгая схема алерта

Обязательны правило, критичность, метрика и порог — на них опирается корреляция.

2. ДЕТЕРМИНИРОВАННОЕ ЯДРО

Классификация

Критичность определяется правилами; неизвестный ярлык трактуется как warning, не ломающая обработку.

Корреляция конечным автоматом

Дедупликация повторов, свертка связанных сигналов, подавление «мигающих» источников.

Наблюдаемое решение

Каждое решение публикуется в отдельный топик и доступно через API — решение является артефактом, а не скрытым состоянием.

Критический путь

Отказ хранилища не прерывает обработку; Kafka отделяет приём от обработки и переживает всплески.

ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ: МАРШРУТИЗАЦИЯ, ИИ И WEB

МАРШРУТИЗАЦИЯ

Реестр маршрутизации

«сервис → команда → дежурный → адрес доставки». Получатель определяется до обращения к модели.

Диспетчер доставки

Читает запросы из Kafka, отправляет сообщение и публикует результат: доставлено / не доставлено.

TrueConf Bot

Обязательный канал: webhook → бот → личный чат; фиксируется статус доставки.

ИИ-КОНТУР

Сценарии

Обогащение алерта + формулировка уведомления; локальный инференс vLLM/Qwen.

Fire-and-forget

ИИ вызывается асинхронно после детерминированного решения и не задерживает доставку.

Полный fallback

Timeout, недоступность модели или некорректный JSON → детерминированный текст из полей алерта.

WEB-ИНТЕРФЕЙС

Два контура

Управление: пользователи, матрица ответственности, системы, маршрутизация, роли, SLA, интеграции, аудит.

Мониторинг

Инциденты, алерты, события, решения корреляции; состояние компонентов читается с backend в реальном времени.

Единый origin

nginx reverse proxy → API платформы; сессионная cookie проходит через проху, CORS не требуется.



ИСПОЛЬЗОВАНИЕ ИНСТРУМЕНТОВ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА



АЛЕРТ

детерминированное решение

KAFKA

AI request

vLLM + QWEN

локальная генерация

AI RESULT

структурированный ответ

FALLBACK

при ошибке

1. ЧТО ДЕЛАЕТ ИИ

- ★ обогащает алерт семантическим контекстом
- ★ формирует гипотезу первопричины
- ★ определяет приоритет в рамках заданного словаря
- ★ формирует заголовок и текст уведомления

2. КАК КОНТРОЛИРУЕТСЯ

- ★ единственный сетевой стык с моделью
- ★ ограниченный JSON-контракт
- ★ уверенность приводится к [0; 1]
- ★ значения вне словаря не принимаются как доверенные

3. ЕСЛИ ИИ НЕДОСТУПЕН

- ★ timeout / ошибка / некорректный JSON
- ★ критический путь продолжает работу
- ★ используется детерминированный текст из полей алерта
- ★ в payload фиксируется путь формирования текста

ИИ В РАЗРАБОТКЕ

LLM-инструменты применялись для генерации и рефакторинга кода, подготовки тестовых сценариев и документации. Сгенерированный код проходил ревью и тестирование.

РЕЗУЛЬТАТ И ОГРАНИЧЕНИЯ

Корпус: 1053 алерта → 36 уведомлений, снижение шума 96,6%.
Полнота 7/8;



ИНФОРМАЦИОННАЯ БЕЗОПАСНОСТЬ: УГРОЗЫ И МЕРЫ ПРОТИВОДЕЙСТВИЯ



23 сценария угроз → защита входа → защита ИИ → доступ и аудит → отказоустойчивость

ЗАЩИТА ВХОДА И ИНТЕГРАЦИЙ

Аутентификация webhook/API, allowlist, TLS, rate limiting и буферизация.
Дедупликация и контроль повторных событий.

ЗАЩИТА ИИ-КОНТУРА

Локальный инференс; ИИ не блокирует критический путь.
Ограниченный JSON-контракт, словарь значений и fallback.

ДОСТУП И АУДИТ

Ролевая модель и авторизация по объектам.
Журналирование изменений правил и подписок; отдельное хранение аудита.

СОСТОЯНИЕ КОНТРОЛЕЙ

НЕЙТРАЛИЗОВАНО

Y-04, Y-06, Y-07, Y-08, Y-17 — закрыто архитектурно и/или подтверждено тестами.

ЧАСТИЧНО

Rate limiting, IAM, аудит, секреты, сегментация и защита БД — требуют усиления.

НЕЙТРАЛИЗОВАНО / НЕАКТУАЛЬНО

Часть сценариев не применима к пилоту.

КЛЮЧЕВЫЕ ОСТАТОЧНЫЕ РИСКИ

Y-01

Неаутентифицированный webhook → фабрикация событий.

Y-16

Подмена образа / зависимостей / весов модели.

Y-18

Отказ узла → простой платформы.

Y-19

Молчание источника → потеря наблюдаемости.

Y-12

Изменение/удаление аудита → потеря следа.

Y-13

Секреты вне репозитория → нет ротации.

ВЫВОД: базовая защита заложена, но перед промышленным внедрением нужно закрыть остаточные риски



ПРОДУКТОВЫЕ МЕТРИКИ

Уведомлений на инцидент, шт.

Уведомлений не тому адресату, шт.

Доля полезных уведомлений, %

Полнота обнаружения инцидентов

ФАКТОРЫ ВЛИЯНИЯ (УРОВЕНЬ 4)

4.1. Снижение числа уведомлений на инцидент

1/2

4,5

4.2. Снижение числа ошибочных адресаций

2/9

10

4.3. Полнота обнаружения (контрольный фактор)

8/8

8/8

ФИЗИЧЕСКИЕ ПАРАМЕТРЫ (УРОВЕНЬ 3)

3.1. Трудозатраты на разбор оповещений, чел.-ч/год

1 чел.

270

270

3.2. Время простоя из-за задержки реакции, ч/год

1 чел.

30 ч

30 ч

ОПЕРАЦИОННЫЕ КПЭ (УРОВЕНЬ 2)

2.1. Сокращение трудозатрат, млн руб./год

0

2,45

2.2. Снижение потерь от простоя, млн руб./год

0

9,38

СУММ. ОПЕР. КПЭ (УРОВЕНЬ 2)

2.3. Сокращение операционных затрат (в среднем), млн руб./год

11,8

ИНВЕСТИЦИОННЫЕ КПЭ (УРОВЕНЬ 1)

NPV: 13,9 млн руб.
PI/I: 3,1
DPP: 0,8 года
Горизонт расчёта: 3 года


XX Базовое значение XX Целевое значение (достигнутое на пилоте)

ПАРАМЕТРЫ 2, 3, 4 УРОВНЕЙ — СРЕДНЕГОДОВЫЕ (С ВЫХОДА НА ЗАПЛАНИРОВАННЫЙ ОБЪЁМ И ФУНКЦИОНАЛ)



Дерево КПЭ





Обозначения: штриховая рамка — виртуальная машина; скруглённый прямоугольник — контейнер Docker; двойная рамка — узел, тиражируемый по горизонтали. Каждый стек разворачивается независимо (Docker Compose).

